



Verificación biométrica de identidad para plataformas de gestión de personal tercerizado

Autor:

Denis Zhbakov

Director:

Ksenija Blažević (Head of Machine Learning & AI)

*Esta planificación fue realizada en el curso de Gestión de proyectos
entre el 23 de junio de 2026 y el 18 de agosto de 2026.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar	6
2. Identificación y análisis de los interesados	9
3. Propósito del proyecto	10
4. Alcance del proyecto	10
5. Supuestos del proyecto.	12
6. <i>Product backlog</i>	12
6.1 Criterio de ponderación: <i>story points</i>	12
6.2 Épica 1: Registro y verificación documento–rostro	13
6.3 Épica 2: Verificación de identidad al inicio de turno	14
6.4 Épica 3: Evaluación experimental y <i>fine-tuning</i>	14
6.5 Épica 4: <i>Harness</i> de evaluación, <i>demo</i> y entrega	16
7. Criterios de aceptación de historias de usuario	16
7.1 Épica 1: Registro y verificación documento–rostro	17
7.2 Épica 2: Verificación de identidad al inicio de turno	18
7.3 Épica 3: Evaluación experimental y <i>fine-tuning</i>	18
7.4 Épica 4: <i>Harness</i> de evaluación, <i>demo</i> y entrega	20
8. Fases de CRISP-DM	21
8.1 Fase 1: Comprensión del negocio	21
8.2 Fase 2: Comprensión de los datos	21
8.3 Fase 3: Preparación de los datos	22
8.4 Fase 4: Modelado	22
8.5 Fase 5: Evaluación	23
8.6 Fase 6: Despliegue	24
9. Desglose del trabajo en tareas	24
10. Planificación de Sprints	30
11. Diagrama de Gantt (sprints)	34
12. Gobernanza de datos	36
12.1 Cumplimiento normativo	36
12.1.1 Normativas aplicables	36
12.1.2 Fuentes de datos y licencias	37
12.1.3 Herramientas y modelos preentrenados	37
12.1.4 Viabilidad legal	38
12.2 Ética en el uso de inteligencia artificial	38
12.2.1 Sesgos en los datos y los modelos	38
12.2.2 Riesgos de impacto social	39
12.2.3 Medidas de mitigación	39
12.2.4 Reflexión ética general	40
13. Gestión de riesgos	40

14. Sprint Review	43
15. Sprint Retrospective	45

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	23 de junio de 2026
1	Se completa hasta el punto 5 inclusive	3 de julio de 2026
2	Se completan los puntos 6 y 7	10 de julio de 2026
3	Se completa hasta el punto 12 inclusive	27 de julio de 2026
4	Se completa todo	28 de julio de 2026

Acta de constitución del proyecto

Buenos Aires, 23 de junio de 2026

Por medio de la presente se acuerda con Denis Zhbankov que su trabajo final de la Carrera de Especialización en Inteligencia Artificial se titulará “Verificación biométrica de identidad para plataformas de gestión de personal tercerizado” y consistirá en el diseño, ajuste fino de adaptación al dominio y evaluación de un módulo de verificación biométrica que, mediante reconocimiento facial, permita contrastar la identidad de los trabajadores al inicio de cada turno laboral y frente a la fotografía del documento de identidad presentado, y contribuya así a verificar la correspondencia de identidad en la plantilla externa. El trabajo se ejecuta en un marco académico (evaluación con *datasets* públicos, ajuste fino de modelos preentrenados e integración mediante *harness* CLI y *demo* interactiva), con un presupuesto preliminar estimado de 600 horas y un costo económico de referencia de USD 36000, calculado a una tarifa profesional de mercado (USD 60/h) para proyectos de consultoría en IA de esta envergadura, sin implicar el cobro efectivo al cliente bajo el acuerdo académico, con fecha de inicio el 23 de junio de 2026 y fecha de presentación pública el 23 de abril de 2027.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Alina Morozovskaia
product owner, empresa externa (NDA)

Ksenija Blažević
Director del trabajo final

1. Descripción técnica-conceptual del proyecto a realizar

El presente trabajo se desarrolla en el marco de Leroy Merlin, empresa internacional del sector de mejoramiento del hogar, que enfrenta una problemática recurrente en la gestión de personal operativo tercerizado (mozos de depósito, personal de limpieza, mecánicos, peones): la falta de certeza de que la persona presente sea la misma que figura en la documentación o en el registro laboral. En la práctica, el riesgo operativo se concentra en dos situaciones de correspondencia de identidad: (1) en la selección, que quien se presenta ante el reclutador no coincida con la fotografía del documento de identidad exhibido; y (2) en la operación diaria, que quien asiste a un turno no sea la misma persona que fue dada de alta como trabajador. Queda fuera del problema tratado en este trabajo la determinación de si el documento de identidad es auténtico o falsificado, así como la verificación de que la imagen capturada corresponda a una persona en vivo y no a una reproducción.

En cuanto al estado del arte, el reconocimiento facial es un campo maduro con arquitecturas de referencia como ArcFace y AdaFace para la generación de *embeddings* faciales, y modelos de detección como MTCNN y RetinaFace. Adicionalmente, TransFace (CVPR 2023) representa una extensión reciente basada en *transformers* que reporta mejoras incrementales sobre ArcFace en *benchmarks* recientes; se incluye como modelo opcional de evaluación si el cronograma lo permite. La pregunta central que motiva este trabajo no es ya qué modelo preentrenado es mejor en abstracto (esa pregunta tiene respuesta conocida en la literatura), sino cuánto mejora un modelo de reconocimiento facial al ajustarse mediante *fine-tuning* de adaptación al dominio, sobre un subconjunto de un *dataset* público aumentado con degradaciones sintéticas que emulan las condiciones operativas adversas (desenfoque, compresión, baja resolución) y muestreo orientado a diversidad de edad, y cuál es el *trade-off* de costo computacional asociado. Esta pregunta es relevante porque las soluciones genéricas no contemplan las condiciones operativas particulares del contexto laboral operativo: heterogeneidad en la calidad de dispositivos de captura, iluminación no controlada, envejecimiento entre la foto del documento y la imagen actual, y calidad variable de los documentos digitalizados.

La solución propuesta consiste en un módulo de verificación biométrica basado en *fine-tuning* de adaptación al dominio de modelos preentrenados modernos (ArcFace y AdaFace como modelos principales, TransFace como opcional) sobre un subconjunto de un *dataset* público de gran escala (Glint360K o WebFace4M) aumentado con degradaciones sintéticas (desenfoque, compresión, baja resolución) y con muestreo orientado a diversidad de edad, a fin de aproximar el subconjunto de entrenamiento a las condiciones operativas adversas del dominio objetivo, y su evaluación sistemática sobre tres *benchmarks* estándar con condiciones complementarias: LFW (*benchmark* clásico saturado, esperable ¿99% en ambos modelos), AgeDB (verificación *cross-age*, que ataca directamente el problema de envejecimiento declarado) y RFW (*Racial Faces in the Wild*, que mide sesgo demográfico y se vincula con la sección de gobernanza). El proyecto se ejecuta en un contexto académico sin acceso directo a datos operativos de la empresa; la integración se materializa mediante un *harness* CLI que ejecuta el *pipeline* completo sobre los *benchmarks* y produce métricas reproducibles, y una *demo* interactiva con Gradio para la presentación. A fin de cerrar el lazo entre el entrenamiento y la evaluación en condiciones adversas, las mismas degradaciones sintéticas aplicadas al subconjunto de *fine-tuning* se aplican también para construir variantes degradadas de LFW y AgeDB, que emulan la heterogeneidad de calidad de captura del dominio operativo y permiten medir de manera comparable el rendimiento en condiciones adversas controladas, tanto del modelo preentrenado como del ajustado.

El *pipeline* técnico central consiste en: (1) detección facial mediante modelos como MTCNN o RetinaFace; (2) alineación basada en *landmarks*; (3) generación de *embeddings* faciales mediante

ArcFace o AdaFace, en su configuración preentrenada o con *fine-tuning* sobre el subconjunto seleccionado; (4) cálculo de similitud por distancia coseno entre el *embedding* del sujeto presente y el de referencia; (5) decisión umbralizada que equilibre la tasa de falsos positivos y falsos negativos según los requerimientos de seguridad del escenario; y (6) un módulo mínimo de *liveness* basado en un modelo preentrenado, que opera como *baseline* extensible (no como sistema de producción). Se incluye también una *demo* interactiva que materializa los flujos de captura y verificación para la presentación.

En la figura 1 se presenta el diagrama en bloques del sistema, que distingue los dos flujos funcionales del prototipo. El flujo de registro (verificación documento–rostro) parte de dos entradas: la captura en vivo mediante la cámara del dispositivo y el documento de identidad digitalizado. Ambas imágenes atraviesan las etapas de detección facial con validación de calidad (un único rostro, nitidez e iluminación suficientes), alineación basada en *landmarks* y generación del *embedding* facial mediante el modelo seleccionado (ArcFace o AdaFace). El par de *embeddings* resultante se compara por distancia coseno con un umbral configurable y, en paralelo, un clasificador auxiliar de *liveness* evalúa la captura en vivo y aporta su *score* a la decisión. Si la decisión es afirmativa, el *embedding* validado se almacena como referencia en la base de datos; en caso contrario, se solicita una nueva captura o se deriva a revisión manual. El flujo de verificación de turno parte únicamente de la captura en vivo, atraviesa las mismas etapas de procesamiento y compara el *embedding* resultante contra la referencia almacenada, con la verificación de *liveness* como condición adicional de la decisión. Ante un rechazo, el sistema permite hasta tres reintentos, registra la incidencia en auditoría y deriva a revisión manual.

Por tratarse de un proyecto de vinculación con una empresa en el marco académico del posgrado, no contempla financiamiento de programas públicos o privados adicionales. No existen acuerdos de propiedad intelectual que restrinjan la difusión de los resultados.

El valor diferencial de este proyecto radica en tres aspectos. Primero, aborda un dominio de aplicación concreto (verificación de identidad laboral en *outsourcing* operativo) con condiciones operativas particulares que las soluciones genéricas de reconocimiento facial no contemplan. Segundo, propone un análisis experimental sistemático del impacto del *fine-tuning* de adaptación al dominio (con un subconjunto aumentado con las mismas degradaciones sintéticas que se aplican a los *benchmarks* de evaluación) sobre el rendimiento y el costo computacional, un abordaje escasamente reportado en la literatura comparativa reciente y que, a diferencia del ajuste sobre un subconjunto sin transformar, permite formular una pregunta experimental realmente respondible. Tercero, integra consideraciones de equidad y robustez demográfica desde el diseño (evaluación sobre RFW) y sienta las bases para un módulo de *liveness* extensible en una iteración posterior (por ejemplo, en una etapa de maestría), y se basa exclusivamente en *datasets* públicos sujetos a verificación de sus licencias y condiciones de uso para garantizar el cumplimiento de la normativa de protección de datos personales en el ámbito del trabajo final.




Figura 1. Diagrama en bloques del sistema.

2. Identificación y análisis de los interesados

En un proyecto es prioritario conocer y gestionar a los interesados, sus expectativas y sus influencias. Esta sección se enfoca en detallar claramente qué roles debe cumplir cada persona involucrada a lo largo de todo el proceso.

Rol	Nombre y Apellido	Organización	Puesto
Cliente	Alina Morozovskaia	Empresa externa (NDA)	<i>Product owner</i>
Orientadora	Ksenija Blažević	Leroy Merlin	Head of Machine Learning & AI
Responsable	Denis Zhbakov	FIUBA	Alumno
Usuario final	—	Perfiles operativos de Leroy Merlin	Especialista de RRHH, supervisor de turno

El proyecto se enmarca en Leroy Merlin como empresa adoptante y propietaria del problema, representada institucionalmente por la orientadora. El rol de cliente (guía de valor de negocio y aprobación de entregables) lo ejerce Alina Morozovskaia, *product owner* de una empresa externa con vínculo bajo NDA, sin relación societaria con Leroy Merlin. Esta configuración se debe a que el vínculo con Leroy Merlin en el marco del presente trabajo final se canaliza a través de la orientadora como referente institucional, y el cliente opera desde una organización distinta con acuerdo de confidencialidad propio, lo que se documenta explícitamente para delimitar el alcance de la validación con *datasets* públicos.

Principales características de los interesados:

- Cliente (Alina Morozovskaia): actúa como *product owner* bajo NDA. Expectativas: que el prototipo demuestre los flujos de verificación, que el análisis experimental sea riguroso y que los resultados aporten evidencia técnica útil para una eventual decisión de despliegue. Influencia: alta — define prioridades del *backlog* y aprueba el cierre. Información que recibe: avances periódicos, resultados de evaluación, documentación técnica. Entregables que revisa: *backlog* priorizado, *harness* de evaluación y resultados, documentación, entregable final del trabajo.
- Orientadora (Ksenija Blažević): experta en *machine learning*. Expectativas: que las decisiones técnicas estén fundamentadas y que la evaluación experimental sea rigurosa y reproducible. Influencia: alta — supervisa la dirección técnica y valida la elección de modelos y protocolos. Información que recibe: requerimientos, resultados de experimentos, métricas de rendimiento. Entregables que revisa: selección de arquitecturas, configuración de *fine-tuning*, informe comparativo, *harness* de evaluación. Supervisa la definición de requerimientos técnicos, la selección de arquitecturas, el *fine-tuning* y la evaluación del *pipeline* biométrico.
- Responsable (Denis Zhbakov): Expectativas: completar el trabajo final con calidad, dentro del plazo y las horas estimadas. Influencia: media — ejecuta y documenta, pero depende de las decisiones del cliente y la orientadora. Información que recibe: reuniones con cliente y orientadora, retroalimentación sobre entregables. Entregables que revisa: todo el código, la documentación técnica y la memoria del trabajo final. Encargado de

planificar, implementar, ajustar, evaluar y documentar el prototipo hasta la defensa del trabajo final. En el contexto académico del trabajo, el rol de administrador del prototipo que aparece en las historias de usuario (HU7, HU11 y HU12) es ejercido por el propio responsable.

- Usuario final (especialista de RRHH, supervisor de turno): Expectativas: que el sistema sea intuitivo, rápido y confiable para los flujos de registro y verificación. Influencia: baja — son usuarios de referencia del prototipo; no participan en decisiones del proyecto. Información que recibe: *demo* interactiva, manuales de uso. Entregables que revisa: *demo* y experiencia de uso en las pruebas con *datasets* públicos. Los roles operativos de referencia del prototipo son el especialista de RRHH (flujo de registro y verificación documento–rostro) y el supervisor de turno (flujo de verificación al inicio de jornada). En este trabajo no se despliega el sistema sobre operaciones reales de Leroy Merlin; dichos roles guían el diseño de la *demo* y de las historias de usuario.

3. Propósito del proyecto

El propósito de este proyecto es diseñar, ajustar, evaluar y documentar, en un marco académico, un módulo de verificación biométrica basado en reconocimiento facial, con el fin de responder experimentalmente la pregunta: ¿cuánto mejora un modelo moderno de verificación facial (ArcFace, AdaFace) al ajustarse mediante *fine-tuning* de adaptación al dominio, sobre un subconjunto de un *dataset* público aumentado con degradaciones sintéticas que emulan las condiciones operativas adversas (desenfoco, compresión, baja resolución) y muestreo orientado a diversidad de edad, medido sobre *benchmarks* estándar con condiciones operativas realistas (envejecimiento, sesgo demográfico, degradación), y cuál es el *trade-off* de costo computacional asociado? El prototipo se aplica al dominio de verificación de identidad en la gestión de personal tercerizado de Leroy Merlin, y se complementa con un módulo mínimo de *liveness* y una *demo* interactiva. La evaluación se realiza sobre *datasets* públicos y el *pipeline* se materializa mediante un *harness* CLI y una UI de demostración. No forma parte del propósito detectar documentación falsificada, validar la autenticidad del documento de identidad, ni certificar el sistema para producción; el módulo de *liveness* incluido es un *baseline* extensible y se documenta como línea de trabajo futuro en una etapa posterior (por ejemplo, en una maestría).

4. Alcance del proyecto

El proyecto incluye:

- implementación de un *pipeline* de verificación biométrica basado en modelos preentrenados modernos (ArcFace, AdaFace): detección facial, alineación, generación de *embeddings* y comparación por similitud;
- verificación de correspondencia entre el rostro en vivo y la fotografía del documento en el flujo de registro, y verificación facial frente a la referencia almacenada al inicio de turno;
- módulo de comparación biométrica con umbralización configurable para balancear seguridad y usabilidad;
- *fine-tuning* de adaptación al dominio de al menos uno de los modelos (ArcFace o AdaFace) sobre un subconjunto seleccionado de un *dataset* público de gran escala (Glint360K)

o WebFace4M), aumentado con degradaciones sintéticas (desenfoque, compresión, baja resolución) y muestreo orientado a diversidad de edad, a fin de aproximar el subconjunto de entrenamiento a las condiciones operativas adversas del dominio objetivo, con evaluación de su impacto frente a la versión preentrenada;

- evaluación comparativa de los modelos preentrenados y ajustados sobre al menos tres *benchmarks* públicos: LFW (*baseline*), AgeDB (*cross-age*) y RFW (sesgo demográfico), así como sobre variantes degradadas sintéticamente de LFW y AgeDB (desenfoque, compresión, baja resolución), con métricas EER, FAR, FRR, curva ROC, AUC, TAR a FAR fijo (por ejemplo, TAR con FAR = 10^{-3}) y tiempo medio de inferencia. Los modelos principales son ArcFace y AdaFace; TransFace (CVPR 2023) puede incluirse como tercer modelo opcional si el cronograma lo permite, a fin de ampliar la cobertura del estado del arte;
- módulo mínimo de *liveness* basado en un modelo preentrenado (por ejemplo, MiniFASNet o FeatherNet) evaluado sobre un *dataset* público de *spoofing* (OULU-NPU o CASIA-FASD), operando como *baseline* extensible;
- *harness* de evaluación end-to-end ejecutable como CLI o notebook parametrizable, que corra el *pipeline* completo sobre un *benchmark* y produzca métricas y figuras reproducibles;
- *demo* interactiva con Gradio o Streamlit para la presentación del prototipo;
- documentación que incluya: informe de avance, memoria técnica, manual de uso del prototipo, documentación del *harness* y repositorio con instrucciones de reproducción de experimentos.

El presente proyecto no incluye:

- validación de autenticidad, integridad o vigencia de documentos de identidad (detección de documentos falsificados, manipulación de soportes, OCR de seguridad, *chips* o códigos de verificación oficiales);
- *liveness detection* robusta para producción: el módulo incluido opera como *baseline* académico y no como sistema anti-*spoofing* certificado. Su desarrollo robusto queda como línea de trabajo futuro;
- entrenamiento desde cero de modelos de reconocimiento facial: el proyecto parte de pesos preentrenados y, en su caso, realiza *fine-tuning* limitado sobre un subconjunto del *dataset*;
- recolección de imágenes biométricas de trabajadores ni datos internos de la empresa. La evaluación se realizará exclusivamente con *datasets* públicos o sintéticos autorizados para uso académico;
- desarrollo de la plataforma de gestión de personal de Leroy Merlin ni de sus funcionalidades existentes;
- despliegue en producción, integración con sistemas reales de la empresa ni mantenimiento post-entrega;
- desarrollo de *hardware* de captura o adquisición de cámaras;
- certificación externa del módulo de *liveness* o auditoría formal de seguridad;
- certificación de cumplimiento de HIPAA, ISO u otros marcos normativos, aunque sí se contempla el análisis de cumplimiento normativo aplicable al tratamiento de datos biométricos y personales (sección 12).

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone que:

- Será posible acceder a *datasets* públicos con cantidad y calidad suficientes para realizar la evaluación y el *fine-tuning*, dentro de las limitaciones del proyecto. En particular, Glint360K (o WebFace4M como alternativa) estará disponible para descarga académica con licencia compatible.
- Las condiciones de licencia de cada *dataset* público utilizado serán verificadas antes de su empleo y documentadas en la sección de gobernanza de datos.
- Se cuenta con acceso a recursos computacionales suficientes (GPU o equivalente) para la experimentación, inferencia y *fine-tuning* de los modelos. En caso de no disponer de *hardware* local adecuado, se recurrirá a *platforms* de cómputo gratuitas o de bajo costo (Google Colab, Kaggle, Lightning AI) dentro de los límites de uso gratuito disponibles. Si el *fine-tuning* requiere recursos adicionales no cubiertos por los *tiers* gratuitos, se contempla un presupuesto de bajo costo consistente con la mitigación planificada para el Riesgo 1: una suscripción *Colab Pro* del orden de USD 10 mensuales como vía principal y, como contingencia, *credits* académicos o de nube de hasta USD 1000 en total a lo largo del proyecto, justificado explícitamente.
- Se dispone del tiempo necesario para completar las 600 horas estimadas del proyecto dentro del plazo establecido.
- Las condiciones macroeconómicas y reglamentarias no sufrirán cambios significativos que afecten la ejecución o el presupuesto del proyecto.
- Se cuenta con las habilidades técnicas necesarias en Python, PyTorch y visión por computadora para implementar la solución. Se contempla una curva de aprendizaje al inicio del proyecto, ya que el responsable se está iniciando en reconocimiento facial; la misma se compensa con la elección de modelos y herramientas bien documentadas (InsightFace, *adaface-pytorch*, Gradio).
- El *fine-tuning* se realiza sobre un subconjunto representativo de un *dataset* público, no sobre datos reales de la empresa, por lo que la pregunta experimental se acota a la mejora sobre condiciones sintéticas de dominio.
- Los cambios de alcance serán excepcionales y se gestionarán mediante acuerdo con la orientadora y el cliente.

6. *Product backlog*

El *product backlog* se organiza en cuatro épicas alineadas con el problema de correspondencia de identidad, el alcance académico del prototipo y los resultados experimentales esperados. Las historias describen funcionalidades del módulo de demostración; no implican despliegue operativo en Leroy Merlin.

6.1. Criterio de ponderación: *story points*

Cada historia de usuario se evalúa según tres dimensiones:

- Dificultad: cantidad de trabajo estimado (escala del 1 al 8).
- Complejidad: nivel técnico requerido (escala del 1 al 8).
- Incertidumbre: riesgo o novedad asociada (escala del 1 al 8).

La suma de las tres dimensiones se redondea hacia el número superior más próximo de la serie de Fibonacci: 1, 2, 3, 5, 8, 13, 21, 34... Los *story points* son relativos y no equivalen directamente a horas de trabajo.

6.2. Épica 1: Registro y verificación documento–rostro

HU1: Captura facial del candidato

- Como especialista de RRHH, quiero capturar el rostro de un candidato mediante la cámara del dispositivo, a fin de generar y almacenar su representación biométrica como referencia futura.
- Prioridad: alta
- Dificultad: 5, complejidad: 5, incertidumbre: 4
- *Story points*: 21

HU2: Extracción de rostro desde documento de identidad

- Como especialista de RRHH, quiero que el sistema extraiga el rostro de la fotografía del documento de identidad (DNI, licencia, carné) para usarlo en el cotejo biométrico del alta.
- Prioridad: alta
- Dificultad: 5, complejidad: 5, incertidumbre: 5
- *Story points*: 21

HU3: Verificación documento–rostro en la selección

- Como especialista de RRHH, quiero que el sistema compare el rostro capturado en vivo con el rostro extraído del documento y emita una decisión de aceptación o rechazo.
- Prioridad: alta
- Dificultad: 5, complejidad: 6, incertidumbre: 5
- *Story points*: 21

HU4: Manejo de capturas inválidas

- Como especialista de RRHH, quiero que el sistema detecte y notifique situaciones anómalas en la captura (ningún rostro detectado, varios rostros, imagen desenfocada, iluminación insuficiente, rostro parcialmente oculto) y solicite una nueva captura.

- Prioridad: alta
- Dificultad: 5, complejidad: 5, incertidumbre: 3
- *Story points*: 13

6.3. Épica 2: Verificación de identidad al inicio de turno

HU5: Verificación facial al inicio de turno

- Como supervisor de turno, quiero que el sistema verifique al inicio de cada turno, mediante reconocimiento facial frente a la referencia almacenada, que la persona presente corresponda a la registrada en el alta.
- Prioridad: alta
- Dificultad: 8, complejidad: 5, incertidumbre: 5
- *Story points*: 21

HU6: Reintento y gestión de rechazos

- Como supervisor de turno, quiero que el sistema permita hasta tres reintentos ante un rechazo o captura inválida y, de persistir, derive a revisión manual y registre la incidencia.
- Prioridad: media
- Dificultad: 3, complejidad: 3, incertidumbre: 3
- *Story points*: 13

6.4. Épica 3: Evaluación experimental y *fine-tuning*

Esta épica concentra el núcleo experimental del trabajo. Su objetivo es producir resultados reproducibles sobre *benchmarks* estándar que respondan la pregunta central del proyecto.

HU7: Configuración del umbral de aceptación

- Como administrador del prototipo, quiero seleccionar y configurar un umbral de distancia coseno previamente evaluado, a fin de equilibrar seguridad (FAR) y usabilidad (FRR) según el escenario de referencia.
- Prioridad: alta
- Dificultad: 5, complejidad: 5, incertidumbre: 3
- *Story points*: 13

HU8: Evaluación comparativa de arquitecturas preentrenadas

- Como orientadora técnica, quiero un análisis comparativo de las arquitecturas de generación de *embeddings* seleccionadas (ArcFace, AdaFace y, opcionalmente, TransFace) en configuración preentrenada, sobre los *benchmarks* LFW, AgeDB y RFW y sobre las variantes degradadas de LFW y AgeDB, con métricas EER, FAR, FRR, AUC, TAR a FAR fijo, curva ROC, tiempo medio de inferencia y uso de memoria, a fin de establecer el *baseline* experimental.
- Prioridad: alta
- Dificultad: 8, complejidad: 8, incertidumbre: 5
- *Story points*: 21

HU9: *Fine-tuning* de adaptación al dominio

- Como orientadora técnica, quiero que al menos uno de los modelos sea ajustado mediante *fine-tuning* de adaptación al dominio sobre un subconjunto seleccionado de Glint360K o WebFace4M, aumentado con degradaciones sintéticas (desenfoco, compresión, baja resolución) y con muestreo orientado a diversidad de edad, documentando la partición de datos, el esquema de *freeze* de capas, el *learning rate* y el número de épocas, a fin de cuantificar la mejora frente a la versión preentrenada, especialmente sobre los *benchmarks* degradados y *cross-age*. Si el cronograma lo permite, se ajustará también un segundo modelo (por ejemplo, AdaFace o TransFace) para ampliar la comparativa.
- Prioridad: alta
- Dificultad: 8, complejidad: 8, incertidumbre: 5
- *Story points*: 21

HU10: Re-evaluación post-*fine-tuning* y análisis comparativo

- Como orientadora técnica, quiero que los modelos ajustados se reevalúen sobre los mismos *benchmarks* (LFW, AgeDB, RFW y las variantes degradadas) en idénticas condiciones que la HU8, y que se elaboren tablas, curvas ROC superpuestas y un análisis de *trade-off* entre precisión y costo computacional, a fin de fundamentar la selección del modelo del prototipo.
- Prioridad: alta
- Dificultad: 5, complejidad: 6, incertidumbre: 3
- *Story points*: 21

HU11: Módulo de *liveness* (*baseline*)

- Como administrador del prototipo, quiero integrar un clasificador de *liveness* preentrenado (por ejemplo, MiniFASNet o FeatherNet) capaz de discriminar entre rostro genuino y ataque de presentación (foto impresa, *replay*), evaluado sobre un *dataset* público de *spoofing* (OULU-NPU o CASIA-FASD), a fin de contar con un *baseline* documentado y extensible.
- Prioridad: media

- Dificultad: 3, complejidad: 5, incertidumbre: 4
- *Story points*: 13

6.5. Épica 4: *Harness* de evaluación, *demo* y entrega

HU12: *Harness* de evaluación end-to-end

- Como administrador del prototipo, quiero un *harness* ejecutable como CLI o notebook parametrizable que corra el *pipeline* completo (detección, alineación, *embedding*, comparación, decisión) sobre un *benchmark* seleccionado y produzca métricas y figuras reproducibles (ROC, EER, FAR, FRR, AUC, tiempo de inferencia), a fin de permitir la verificación independiente de los resultados.
- Prioridad: alta
- Dificultad: 5, complejidad: 5, incertidumbre: 2
- *Story points*: 13

HU13: *Demo* interactiva y documentación

- Como usuario final (RRHH o supervisor de turno), quiero una *demo* interactiva con Gradio o Streamlit que permita ejecutar los flujos de registro y verificación y visualizar el resultado, y documentación de uso del *harness* y de la *demo*, a fin de contar con material claro para la presentación y para eventuales réplicas.
- Prioridad: media
- Dificultad: 3, complejidad: 2, incertidumbre: 2
- *Story points*: 8

7. Criterios de aceptación de historias de usuario

Los criterios de aceptación se definen para cada historia de usuario del *product backlog*, de modo que puedan validarse las condiciones necesarias para considerar cumplida la funcionalidad. Cada historia tiene criterios medibles, específicos y verificables. Se incluyen al menos tres criterios por historia: uno funcional, uno visual y uno técnico (cuando aplica). En la HU8, HU9 y HU10 el criterio “visual” se interpreta como presentación clara de resultados (tablas o gráficos en la documentación o en la *demo*).

Cada criterio técnico especifica, cuando corresponde, el conjunto de prueba, el protocolo experimental y el *hardware* de referencia, a fin de garantizar la reproducibilidad. El *hardware* de referencia para todas las métricas de tiempo es un MacBook Pro 16” 2019 (Intel, 16 GB de RAM, AMD Radeon Pro 5300M 4 GB). Las corridas de *fine-tuning* y evaluación se realizan preferentemente en un entorno con GPU con *framework* CUDA (Google Colab, Kaggle o equivalente), a fin de asegurar tiempos de entrenamiento razonables dentro del plazo del trabajo. Se advierte que los tiempos de inferencia medidos en el *hardware* de referencia (CPU/IGPU) son útiles como cotas reproducibles para el prototipo académico y no son representativos de un despliegue productivo sobre GPU; en la memoria se documenta el dispositivo empleado en cada corrida, de modo que las cifras sean trazables y comparables.

7.1. Épica 1: Registro y verificación documento–rostro

Criterios de aceptación HU1: Captura facial del candidato

1. Funcional: el sistema permite ingresar los datos del candidato (nombre, DNI, puesto), capturar su imagen facial mediante la cámara del dispositivo y almacenar el *embedding* generado, asociándolo al candidato correcto.
2. Visual: la interfaz muestra una vista previa de la imagen capturada con el rostro delimitado antes de confirmar el registro.
3. Técnico: se detecta exactamente un rostro en la imagen capturada con un nivel de confianza superior al 80 %, el rostro está alineado y la imagen tiene una resolución mínima de 160×160 píxeles y nitidez suficiente para la generación del *embedding*. El *embedding* resultante se almacena exitosamente y puede recuperarse para comparaciones posteriores.

Criterios de aceptación HU2: Extracción de rostro desde documento de identidad

1. Funcional: el sistema permite cargar una imagen de un documento de identidad (DNI, licencia de conducir, carné de residencia) y extrae la fotografía del titular de manera automática.
2. Visual: se muestra una vista previa de la imagen extraída del documento antes de confirmar el registro, de modo que el usuario pueda validar la calidad.
3. Técnico: sobre un conjunto de al menos 50 imágenes de documentos construidas a partir de *datasets* públicos o datos sintéticos (con variaciones de tipo de documento, ángulo de captura e iluminación), la extracción detecta y recorta el rostro del titular con un *IoU* superior al 70 % respecto de la anotación manual en al menos el 90 % de los casos. La imagen resultante es compatible con el *pipeline* de generación de *embeddings*.

Criterios de aceptación HU3: Verificación documento–rostro en la selección

1. Funcional: el sistema compara el *embedding* del rostro en vivo con el del rostro extraído del documento y emite un resultado de aceptación o rechazo según el umbral configurado.
2. Visual: la interfaz presenta ambas imágenes (o recortes faciales), el resultado del cotejo (aceptado/rechazado) y el nivel de similitud.
3. Técnico: sobre pares derivados de LFW o pares sintéticos controlados, el cotejo alcanza un EER inferior al 10 % y el tiempo total del *pipeline* (detección + alineación + generación de *embedding* + comparación) es inferior a 5 segundos en el *hardware* de referencia.
4. Manejo de errores: ante la ausencia de rostro, la detección de varios rostros o una imagen que no alcanza la calidad mínima, el sistema emite un mensaje descriptivo y solicita una nueva captura sin proceder a la comparación.

Criterios de aceptación HU4: Manejo de capturas inválidas

1. Funcional: el sistema detecta las siguientes situaciones anómalas y notifica al usuario con un mensaje descriptivo: ningún rostro detectado, varios rostros detectados, imagen desenfocada, iluminación insuficiente, rostro parcialmente oculto.

2. Visual: cada tipo de error se distingue visualmente (por ejemplo, con un mensaje o ícono específico) y la interfaz indica la acción correctiva esperada.
3. Técnico: la detección de calidad de imagen (nitidez, iluminación, oclusión) se realiza antes de la generación del *embedding*, evitando procesar entradas no válidas. En el conjunto de pruebas con al menos 20 imágenes por cada tipo de error, la tasa de detección correcta de la anomalía es superior al 85 %.

7.2. Épica 2: Verificación de identidad al inicio de turno

Criterios de aceptación HU5: Verificación facial al inicio de turno

1. Funcional: el sistema detecta el rostro del trabajador, genera su *embedding*, lo compara con el almacenado y emite un resultado de aceptación o rechazo.
2. Visual: la *demo* muestra la cámara con el rostro detectado y, tras la verificación, un indicador verde (aceptado) o rojo (rechazado) junto con el nivel de similitud.
3. Técnico: el *pipeline* completo (detección, alineación, generación de *embedding*, comparación, decisión) se ejecuta en menos de 5 segundos en el *hardware* de referencia, sobre el protocolo de verificación definido con el *benchmark* de evaluación.
4. Manejo de errores: ante ausencia de rostro, múltiples rostros o calidad insuficiente, el sistema solicita una nueva captura sin emitir decisión.

Criterios de aceptación HU6: Reintento y gestión de rechazos

1. Funcional: ante un rechazo o una captura inválida, el sistema permite hasta tres reintentos. Si tras los reintentos la verificación persiste como rechazada, la *demo* indica que se derive a una revisión manual y registra la incidencia con *timestamp* y datos del intento.
2. Visual: cada reintento muestra un contador (intento 1 de 3, etc.) y, tras el tercer rechazo, se muestra un mensaje de derivación.
3. Técnico: cada intento (rechazo o inválido) queda registrado en el archivo de auditoría con *timestamp*, identificador del trabajador, tipo de fallo y nivel de similitud cuando corresponda.

7.3. Épica 3: Evaluación experimental y *fine-tuning*

Criterios de aceptación HU7: Configuración del umbral de aceptación

1. Funcional: el administrador puede seleccionar entre umbrales previamente evaluados (resultados de HU8, HU9 y HU10) y aplicarlos a las verificaciones posteriores. El panel indica el efecto de cada umbral (más estricto: menor FAR, mayor FRR; más permisivo: mayor FAR, menor FRR).
2. Visual: el panel de configuración muestra el umbral actual, una tabla comparativa de umbrales evaluados con sus métricas asociadas y un control para guardar la selección.

3. Técnico: el umbral seleccionado se persiste en un archivo de configuración y se carga automáticamente al iniciar el sistema.

Criterios de aceptación HU8: Evaluación comparativa de arquitecturas preentrenadas

1. Funcional: se ejecutan las arquitecturas ArcFace y AdaFace en configuración preentrenada sobre los *benchmarks* LFW, AgeDB y RFW y sobre las variantes degradadas de LFW y AgeDB, en idénticas condiciones de preprocesamiento y métrica, y se reportan EER, FAR, FRR, AUC, TAR a FAR fijo, curva ROC, tiempo medio de inferencia y uso de memoria por *embedding*.
2. Visual: los resultados se presentan en tablas comparativas y curvas ROC superpuestas en la documentación y en la *demo*.
3. Técnico: el procedimiento es reproducible. Se documenta la versión de cada modelo, la configuración de inferencia, los *benchmarks* y su protocolo, las semillas aleatorias y la tolerancia esperada de las métricas. Las corridas se ejecutan en el *hardware* de referencia o en un entorno GPU equivalente documentado.

Criterios de aceptación HU9: *Fine-tuning* de adaptación al dominio

1. Funcional: al menos uno de los modelos (ArcFace o AdaFace) se ajusta mediante *fine-tuning* de adaptación al dominio sobre un subconjunto seleccionado de Glint360K o WebFace4M, aumentado con degradaciones sintéticas (desenfoco, compresión, baja resolución) y con muestreo orientado a diversidad de edad, con un esquema documentado de partición, *freeze* de capas, *learning rate*, número de épocas y *batch size*, y los *checkpoints* intermedios se preservan.
2. Visual: las curvas de *loss* y de las métricas de validación durante el entrenamiento se grafican y se incluyen en la documentación.
3. Técnico: la mejora de EER sobre AgeDB y sobre las variantes degradadas de LFW y AgeDB respecto del modelo preentrenado se reporta con un intervalo de confianza o con réplicas suficientes; si la mejora es estadísticamente nula, se documenta y analiza la causa (tamaño del subconjunto, capacidad del modelo, magnitud de las degradaciones, dominio del *dataset*).

Criterios de aceptación HU10: Re-evaluación post-*fine-tuning* y análisis comparativo

1. Funcional: los modelos ajustados se reevalúan sobre LFW, AgeDB, RFW y las variantes degradadas, en idénticas condiciones que la HU8, y se elaboran tablas y figuras que comparan preentrenado vs ajustado.
2. Visual: la documentación incluye curvas ROC superpuestas, tabla de métricas por modelo y *benchmark*, y un gráfico de *trade-off* entre precisión (EER) y costo computacional (tiempo de inferencia).
3. Técnico: el análisis se almacena en un archivo con la configuración experimental completa (modelo, *benchmark*, umbral, versión, semilla, partición), reproducible a partir del *harness* de la HU12.

Criterios de aceptación HU11: Módulo de *liveness* (*baseline*)

1. Funcional: el sistema integra un clasificador de *liveness* preentrenado que, dada una imagen facial, devuelve una probabilidad de “rostro genuino” y aplica un umbral para emitir la decisión.
2. Visual: la *demo* muestra la decisión de *liveness* junto con la decisión de verificación, y un ejemplo de ataque (foto impresa) etiquetado correctamente como ataque en una corrida de demostración.
3. Técnico: sobre el *benchmark* público de *spoofing* seleccionado (OULU-NPU o CASIA-FASD), se reporta el ACER (*Average Classification Error Rate*) o HTER (*Half Total Error Rate*) y se compara con la línea base reportada en la literatura. La elección de umbrales y las limitaciones del *baseline* se documentan explícitamente.

7.4. Épica 4: *Harness* de evaluación, *demo* y entrega

Criterios de aceptación HU12: *Harness* de evaluación end-to-end

1. Funcional: el *harness* acepta por línea de comandos los argumentos mínimos (modelo, *benchmark*, partición, semilla) y produce un directorio de salida con métricas (JSON o CSV) y figuras (PNG) reproducibles.
2. Visual: la documentación del *harness* (formato Markdown) describe los argumentos, las salidas esperadas y un ejemplo de uso.
3. Técnico: la ejecución completa del *harness* sobre el *benchmark* más pequeño (LFW) completa en un tiempo razonable y documentado para el *hardware* de referencia o el entorno GPU empleado (a título orientativo, del orden de decenas de minutos sobre LFW); el tiempo efectivo se registra y reporta en la documentación, de modo que el criterio verificable es la reproducibilidad documentada del tiempo de corrida y no un umbral fijo dependiente del dispositivo. El *README* del repositorio incluye los comandos exactos para reproducir las cifras de la memoria.

Criterios de aceptación HU13: *Demo* interactiva y documentación

1. Funcional: la *demo* en Gradio o Streamlit permite cargar una imagen (o capturarla desde la cámara), seleccionar el modelo y visualizar la decisión de verificación, el nivel de similitud, la decisión de *liveness* y, cuando aplique, el resultado del cotejo documento–rostro.
2. Visual: la *demo* incluye una pestaña o vista de resultados experimentales con las curvas ROC y las tablas comparativas de los modelos.
3. Técnico: la *demo* se ejecuta localmente con un único comando y la documentación describe su puesta en marcha. La documentación del trabajo final incluye, además, el manual de uso del prototipo y las instrucciones de reproducción.

8. Fases de CRISP-DM

El proyecto se adhiere al modelo *Cross-Industry Standard Process for Data Mining* (CRISP-DM), adaptado a las características propias de un sistema de verificación biométrica por reconocimiento facial. A continuación se describe la adaptación de cada fase al contexto del proyecto, con énfasis en la fase experimental que constituye el núcleo del trabajo.

8.1. Fase 1: Comprensión del negocio

Objetivo: comprender el contexto organizacional, los objetivos del proyecto y los criterios de éxito desde la perspectiva del negocio.

El proyecto se enmarca en la necesidad de Leroy Merlin de verificar la correspondencia de identidad de su personal operativo tercerizado. El valor agregado de la inteligencia artificial reside en automatizar el cotejo facial, que de otro modo sería manual, subjetivo y propenso a errores. Las métricas de éxito del negocio son: reducción de incidentes de suplantación de identidad, disminución del tiempo de verificación por turno y disponibilidad de un registro trazable de intentos de verificación. La pregunta experimental del proyecto (*fine-tuning* vs preentrenado, *trade-off* con costo computacional) responde al interés del cliente en contar con evidencia técnica para una eventual decisión de despliegue.

El alcance del prototipo es académico: la validación se realizará con *datasets* públicos y el *fine-tuning* se realiza sobre un subconjunto representativo del dominio, no sobre datos reales de la empresa. No se contempla despliegue operativo en la empresa.

8.2. Fase 2: Comprensión de los datos

Objetivo: identificar las fuentes de datos necesarias, su naturaleza y las condiciones de calidad requeridas para el *fine-tuning* y la evaluación.

Los datos provienen exclusivamente de *datasets* públicos de reconocimiento facial, seleccionados por su volumen, diversidad demográfica y licencia compatible con uso académico. Se utilizarán los siguientes:

- Glint360K (InsightFace): aproximadamente 17 millones de imágenes de 360.000 identidades, recopiladas de fuentes web públicas y distribuidas para investigación no comercial. Se utilizará como fuente principal para el *fine-tuning*, sobre un subconjunto seleccionado.
- WebFace4M (Zenodo, 2023): aproximadamente 4 millones de imágenes de 200.000 identidades, disponible como alternativa moderna y con licencia clara. Se considerará como fuente complementaria si Glint360K no estuviese disponible.
- LFW (*Labeled Faces in the Wild*): más de 13.000 imágenes faciales de 5.749 personas, con pares genuinos y adversarios predefinidos. Se utilizará como *benchmark* de *baseline* (saturado, esperable >99%).
- AgeDB: *benchmark* de verificación *cross-age* con 16.488 imágenes de 568 personas, con rangos etarios de hasta 101 años. Se utilizará para evaluar la capacidad de los modelos ante el envejecimiento entre la foto del documento y la captura en vivo, directamente vinculado al problema declarado.

- RFW (*Racial Faces in the Wild*): *benchmark* diseñado específicamente para medir sesgo demográfico en modelos de reconocimiento facial. Se utilizará para reportar el rendimiento por subgrupo demográfico y vincular el análisis con la sección de gobernanza de datos.
- OULU-NPU o CASIA-FASD: *datasets* públicos de *spoofing* facial, utilizados para la evaluación del módulo de *liveness* (*baseline*).

Nota: se excluyen explícitamente *MS-Celeb-1M* (retractado por Microsoft en 2019 por problemas de consentimiento) y *CASIA-WebFace* (retirado y con licencia ambigua), ambos mencionados en la propuesta original. Las licencias de los *datasets* seleccionados se verificarán antes de su empleo y se documentarán en la sección de gobernanza de datos (sección 12).

8.3. Fase 3: Preparación de los datos

Objetivo: transformar los datos brutos en entradas aptas para el *fine-tuning* y para el *pipeline* de generación de *embeddings*.

Las transformaciones clave son:

- Detección facial: localizar y recortar la zona rostral de cada imagen, eliminando el fondo irrelevante. Se emplearán modelos de detección como MTCNN o RetinaFace.
- Alineación facial: corregir la orientación del rostro detectado mediante alineación basada en puntos de referencia faciales (*landmarks*).
- Normalización: redimensionar los recortes faciales a la resolución de entrada esperada por cada modelo de generación de *embeddings* (112×112 píxeles para ArcFace y AdaFace).
- Generación de *embeddings baseline*: conversión de cada rostro alineado en un vector numérico de dimensionalidad fija (por ejemplo, 512 dimensiones) con el modelo preentrenado.
- Partición de datos: dividir los *datasets* en conjuntos de entrenamiento, validación y prueba, respetando los protocolos de evaluación establecidos para cada *benchmark*.
- Subconjunto de *fine-tuning* de adaptación al dominio: selección de un subconjunto de Glint360K o WebFace4M (por ejemplo, 5.000–10.000 identidades, 100.000–300.000 imágenes) y aplicación de *data augmentation* con degradaciones sintéticas (desenfoque, compresión, baja resolución) que emulan las condiciones adversas del dominio objetivo, junto con muestreo orientado a diversidad de edad, con partición *hold-out* para validación.

8.4. Fase 4: Modelado

Objetivo: seleccionar, configurar y ajustar los modelos de generación de *embeddings* faciales.

El tipo de problema es la verificación de identidad binaria: determinar si dos imágenes faciales corresponden a la misma persona. No se trata de clasificación de identidades sino de estimación de similitud entre representaciones vectoriales.

Los algoritmos evaluados son:

- ArcFace (ResNet-100): red neuronal que emplea una función de pérdida aditiva angular (*Additive Angular Margin Loss*) para generar *embeddings* con alta discriminabilidad. Se utilizará la implementación preentrenada de InsightFace con *weights* públicos, y se realizará *fine-tuning* de adaptación al dominio sobre el subconjunto aumentado con degradaciones sintéticas.
- AdaFace (CVPR 2022): red neuronal que introduce una función de pérdida con margen adaptativo a la calidad (*quality-adaptive margin*), reportando mejoras sobre ArcFace en condiciones adversas. Se utilizará la implementación preentrenada pública, y opcionalmente se ajustará sobre el mismo subconjunto aumentado con degradaciones sintéticas.
- TransFace (CVPR 2023, opcional): arquitectura basada en *transformers* para la generación de *embeddings* faciales, que reporta mejoras incrementales sobre ArcFace en *benchmarks* recientes. Su inclusión queda condicionada a la disponibilidad de tiempo dentro del cronograma y al éxito del *fine-tuning* de adaptación al dominio de los modelos principales. Si se incluye, se evalúa en idénticas condiciones que ArcFace y AdaFace y se reporta en una fila adicional de las tablas comparativas, con la advertencia explícita de que es resultado de una iteración opcional y no afecta los hallazgos principales del trabajo.

El método de comparación entre *embeddings* es la distancia coseno. La decisión se realiza mediante un umbral configurable que balancea la tasa de falsos aceptos (FAR) y la tasa de falsos rechazos (FRR).

8.5. Fase 5: Evaluación

Objetivo: medir el rendimiento de los modelos y fundamentar la elección del modelo del prototipo, con énfasis en la comparación preentrenado vs ajustado.

Las métricas de rendimiento son:

- *Equal Error Rate* (EER): punto en el que FAR y FRR son iguales; se busca minimizarlo.
- *False Acceptance Rate* (FAR): proporción de pares adversarios aceptados erróneamente.
- *False Rejection Rate* (FRR): proporción de pares genuinos rechazados erróneamente.
- Curva ROC (*Receiver Operating Characteristic*): representación gráfica del compromiso entre sensibilidad y especificidad.
- AUC (*Area Under the Curve*): área bajo la curva ROC; capacidad discriminativa global.
- TAR a FAR fijo (*True Acceptance Rate* a un *False Acceptance Rate* determinado, por ejemplo FAR = 10^{-3}): tasa de aceptación genuina en un punto operativo de seguridad exigente; métrica de referencia habitual en la industria biométrica.
- Tiempo medio de inferencia por *embedding* y uso de memoria, en el *hardware* de referencia.

Los *benchmarks* utilizados son:

- LFW: *baseline* clásico, esperable saturación en ambos modelos.

- AgeDB: *cross-age*, donde se espera observar la mayor mejora por *fine-tuning*.
- RFW: sesgo demográfico, con reporte por subgrupo.
- Variantes degradadas de LFW y AgeDB: imágenes con desenfoque, compresión y baja resolución aplicados de manera sintética, que emulan la heterogeneidad de calidad de captura del dominio operativo. Los mismos operadores de degradación aplicados al subconjunto de *fine-tuning* (fase de preparación) generan estas variantes de evaluación, de modo que el lazo entrenamiento-evaluación se mantenga comparable y la mejora (o su ausencia) sea interpretable en términos de adaptación al dominio.
- OULU-NPU o CASIA-FASD (para *liveness*): ACER/HTER.

8.6. Fase 6: Despliegue

Objetivo: integrar el modelo seleccionado en un prototipo demostrable y documentar los resultados de manera reproducible.

Dado el alcance académico del proyecto, el despliegue se limita a:

- *Harness* CLI o notebook parametrizable que ejecuta el *pipeline* completo sobre los *benchmarks* seleccionados y produce métricas y figuras reproducibles.
- *Demo* interactiva con Gradio o Streamlit que materializa los flujos de captura y verificación para la presentación.
- Repositorio con documentación técnica, instrucciones de reproducción de experimentos y *scripts* de evaluación.

No se contempla despliegue en producción, integración con sistemas reales de Leroy Merlin ni mantenimiento post-entrega.

9. Desglose del trabajo en tareas

A partir de cada historia de usuario definida en la sección 6, se descompone el trabajo en tareas técnicas concretas, medibles y acotadas en el tiempo. Cada tarea se estima en horas y se le asigna una prioridad relativa (Alta, Media o Baja) según su relevancia funcional y su impacto en los entregables. Dado el carácter individual del proyecto y la granularidad de las historias de usuario, las tareas técnicas se estiman en un rango de 6 a 30 horas, agrupando subtareas afines que se ejecutan de manera contigua. Esta desviación respecto del rango sugerido de 2 a 8 horas se adopta deliberadamente, a fin de preservar la trazabilidad entre tareas y entregables sin fragmentar artificialmente el trabajo; las actividades no técnicas, de naturaleza continua, se descomponen en bloques asociados a cada sprint, con estimaciones de 6 a 32 horas.

La suma total de las horas técnicas (388 h) más las actividades no técnicas (212 h) asciende a 600 h, que coincide con el presupuesto total del proyecto distribuido a lo largo de los 12 sprints (sección 10).

La suma de las estimaciones de las tareas técnicas asciende a 388 horas y la de las actividades no técnicas a 212 horas, totalizando 600 horas estimadas en la desagregación, coherente con la

Cuadro 1. Desglose de tareas por historia de usuario (1/5).

Historia de usuario	Tarea técnica	Estimación	Prioridad
Infra.	Configuración del entorno de desarrollo (Python, PyTorch, CUDA), instalación de dependencias (MTCNN, RetinaFace, InsightFace, <i>adaface-pytorch</i>) y preparación del repositorio	20 h	Alta
HU1	Implementación del módulo de captura facial: interfaz de captura desde cámara, detección del rostro, validación de calidad (un solo rostro, resolución mínima, nitidez) y generación del <i>embedding</i> de referencia	28 h	Alta
HU1	Implementación del flujo de registro de candidato: asociación del <i>embedding</i> con los datos del candidato (nombre, DNI, puesto) y almacenamiento persistente	10 h	Alta
HU2	Desarrollo del módulo de extracción facial desde imagen de documento: detección automática del recorte del titular en DNI, licencia de conducir o carné de residencia	14 h	Alta
HU2	Validación de la calidad del recorte extraído (alineación, iluminación, resolución) y generación del <i>embedding</i> correspondiente	8 h	Media
HU3	Implementación del módulo de comparación biométrica: cálculo de distancia coseno entre <i>embeddings</i> , aplicación del umbral de decisión y emisión del resultado (aceptado/rechazado)	14 h	Alta
HU3	Integración del flujo completo de verificación documento-rostro: captura en vivo, extracción desde documento, comparación y presentación del resultado con imágenes y nivel de similitud	14 h	Alta

Cuadro 2. Desglose de tareas por historia de usuario (2/5).

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU4	Implementación del módulo de validación de calidad de imagen: detección de oclusión, estimación de nitidez (varianza del Laplaciano), evaluación de iluminación y conteo de rostros detectados	18 h	Alta
HU4	Diseño de la interfaz de notificación de errores: mensajes descriptivos por tipo de anomalía (ningún rostro, varios rostros, imagen desenfocada, iluminación insuficiente, rostro parcialmente oculto) y solicitud de nueva captura	14 h	Media
HU5	Implementación del <i>pipeline</i> de verificación en tiempo interactivo al inicio de turno: captura por cámara, detección facial, generación de <i>embedding</i> , comparación con referencia almacenada y emisión de decisión	16 h	Alta
HU5	Desarrollo de la <i>demo</i> del flujo de turno: vista previa de cámara con rostro detectado, indicador visual de aceptación/rechazado y nivel de similitud	12 h	Alta
HU6	Implementación del mecanismo de reintento: control de intentos (máximo tres), registro de cada intento (rechazo o inválido) y derivación a revisión manual tras el tercer fallo	10 h	Media
HU6	Implementación del registro de incidencias de verificación: <i>timestamp</i> , identificador del trabajador, tipo de fallo y nivel de similitud en cada intento	6 h	Media

Cuadro 3. Desglose de tareas por historia de usuario (3/5).

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU7	Diseño e implementación del panel de configuración de umbral: interfaz para seleccionar entre umbrales previamente evaluados y visualización del efecto de cada umbral (FAR/FRR)	6 h	Alta
HU7	Persistencia del umbral seleccionado en un archivo de configuración y carga automática al iniciar el sistema	4 h	Alta
HU8	Diseño del protocolo experimental: definición de particiones de LFW, AgeDB y RFW, semillas aleatorias, configuración de inferencia (resolución, <i>batch size</i> , dispositivo) y documentación de la configuración	14 h	Alta
HU8	Ejecución de la evaluación <i>baseline</i> : corridas de ArcFace y AdaFace preentrenados sobre LFW, AgeDB y RFW y sobre las variantes degradadas de LFW y AgeDB, con medición de EER, FAR, FRR, AUC, TAR a FAR fijo, curva ROC, tiempo de inferencia y uso de memoria	20 h	Alta
HU8	(Opcional) corrida de TransFace preentrenado sobre los mismos <i>benchmarks</i> para ampliar la comparativa con una arquitectura <i>transformer</i> -based reciente	8 h	Baja
HU9	Preparación del subconjunto de <i>fine-tuning</i> de adaptación al dominio: descarga, filtrado y partición de un subconjunto de Glint360K (o WebFace4M) en <i>train/val</i> , aplicación de <i>data augmentation</i> con degradaciones sintéticas (desenfoco, compresión, baja resolución) y muestreo orientado a diversidad de edad, con documentación de identidades por partición	8 h	Alta
HU9	Ejecución del <i>fine-tuning</i> de adaptación al dominio de ArcFace: configuración de hiperparámetros (<i>learning rate</i> , número de épocas, <i>batch size</i> , esquema de <i>freeze</i>), entrenamiento y registro de curvas de <i>loss</i> /métricas	30 h	Alta
HU9	(Opcional) <i>fine-tuning</i> de adap-	12 h	Baja

Cuadro 4. Desglose de tareas por historia de usuario (4/5).

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU10	Re-evaluación de los modelos ajustados sobre LFW, AgeDB y RFW en idénticas condiciones que la HU8, con almacenamiento de los resultados en formato reproducible	20 h	Alta
HU10	Análisis comparativo preentrenado vs ajustado: tablas, curvas ROC superpuestas, análisis de <i>trade-off</i> entre EER y tiempo de inferencia, discusión de los resultados por <i>benchmark</i> y fundamentación de la elección del modelo del prototipo	18 h	Alta
HU11	Integración del clasificador de <i>liveness</i> preentrenado (Mini-FASNet o FeatherNet) y evaluación sobre OULU-NPU (o CASIA-FASD), con cálculo de ACER/HTER y documentación de limitaciones del <i>baseline</i>	18 h	Media
HU11	Incorporación de la decisión de <i>liveness</i> al <i>pipeline</i> principal y a la <i>demo</i> , con ejemplo etiquetado de ataque (foto impresa)	14 h	Media
HU12	Implementación del <i>harness</i> CLI: argparse con argumentos (modelo, <i>benchmark</i> , partición, semilla), ejecución del <i>pipeline</i> end-to-end y guardado de métricas y figuras en un directorio de salida	18 h	Alta
HU12	Documentación del <i>harness</i> en formato Markdown: argumentos, salidas esperadas, ejemplo de uso, comandos exactos para reproducir las cifras de la memoria	6 h	Media
HU13	Implementación de la <i>demo</i> interactiva con Gradio o Streamlit: pestañas para verificación en vivo, resultados experimentales y, cuando aplique, cotejo documento-rostro	12 h	Media
HU13	Redacción del manual de uso del prototipo y de las instrucciones de reproducción de experimentos en el repositorio	6 h	Media
Cierre	Ajustes finales al prototipo según observaciones de la orientación	10 h	Media
	Página 28 de 46		

Cuadro 5. Desglose de tareas por historia de usuario (5/5): actividades no técnicas.

Historia de usuario	Tarea técnica	Estimación	Prioridad
No técnica	Planificación inicial: reuniones con la orientadora y el cliente, definición y ajuste del <i>backlog</i> y del cronograma (Sprint 0)	30 h	Alta
No técnica	Informes de avance y reportes intermedios (Sprints 1 y 5)	18 h	Alta
No técnica	Documentación técnica parcial del <i>pipeline</i> (Sprint 3)	18 h	Alta
No técnica	Reuniones de seguimiento y ajuste del cronograma (Sprint 4)	6 h	Alta
No técnica	Monitoreo del entrenamiento y registro de curvas de <i>loss</i> y métricas (Sprint 6)	12 h	Alta
No técnica	Redacción de la sección experimental de la memoria técnica (Sprint 7)	12 h	Alta
No técnica	Revisión integral del <i>pipeline</i> y de la documentación (Sprint 9)	26 h	Alta
No técnica	Preparación de la presentación de defensa y ensayos (Sprint 10)	28 h	Alta
No técnica	Revisión final de la memoria, entrega de documentación, código y repositorio (Sprints 10 y 11)	32 h	Alta
No técnica	Reuniones finales, organización del acto de cierre y agradecimientos (Sprint 11)	30 h	Alta

planificación de sprints y con el presupuesto declarado en el acta de constitución. La proporción de actividades no técnicas (212 h) supera la franja sugerida de 100 a 120 h a causa del peso de la memoria técnica, los informes parciales por bimestre y la preparación de la defensa en un proyecto individual con núcleo experimental; se adopta como una desviación justificada y deliberada. Adicionalmente, se contemplan 20 horas de tareas opcionales (TransFace como tercer modelo de evaluación y como segundo *fine-tuning* de adaptación al dominio), presentes únicamente en el WBS y no en la planificación de sprints, que se ejecutarán solo si el cronograma lo permite y no forman parte del núcleo obligatorio del trabajo.

Para facilitar la trazabilidad entre ambas desagregaciones, las diez filas no técnicas de la tabla anterior se corresponden, una a una y con idéntica estimación horaria, con las filas etiquetadas “No téc.” de la planificación de sprints (sección 10); cada fila no técnica indica entre paréntesis el sprint en el que se ejecuta. Asimismo, la fila técnica “Infra.” del WBS (configuración del entorno, 20 h) corresponde a la fila “Planif.” del Sprint 0, y la fila técnica “Cierre” del WBS (ajustes finales al prototipo, 10 h) corresponde a la fila “—” del Sprint 10. De este modo el WBS y la planificación de sprints coinciden exactamente en 388 h técnicas y 212 h no técnicas (600 h del núcleo obligatorio), difiriendo únicamente en las 20 h opcionales referidas en el párrafo anterior, propias del WBS.

10. Planificación de Sprints

Las tareas del proyecto se organizan en 12 sprints (Sprint 0 al Sprint 11) de 2 a 3 semanas de duración cada uno, distribuidos a lo largo de 4 bimestres curriculares (34 semanas, aproximadamente 8 meses, desde el 24 de agosto de 2026 hasta finales de abril de 2027). Cada sprint concentra 50 horas de trabajo, lo que resulta en una carga promedio de 20 horas semanales (con picos de 25 horas semanales en los sprints de 2 semanas), con semanas de transición entre bimestres dedicadas a repaso, redacción de informes parciales y revisión con la orientadora. El responsable de todas las tareas es el autor del trabajo final. La planificación contempla tanto tareas técnicas derivadas de las historias de usuario como actividades no técnicas (planificación, documentación, reuniones y preparación de la defensa). El núcleo experimental (*fine-tuning* y evaluación sobre *benchmarks* múltiples) se concentra en los sprints 5 a 7, mientras que los sprints 1 a 4 corresponden a la construcción del *pipeline* base y los sprints 8 a 11 a la integración, *liveness*, *demo*, documentación y cierre. El cuarto bimestre (sprints 9 a 11) concentra la *demo*, la revisión integral, la preparación de la defensa y el cierre.

La distribución totaliza 600 horas, distribuidas a lo largo de 12 sprints (Sprint 0 al Sprint 11) en un plazo de 34 semanas (4 bimestres, aproximadamente 8 meses), desde el 24 de agosto de 2026 hasta finales de abril de 2027. La carga promedio es de 20 horas semanales (50 h por sprint de 2 a 3 semanas), con semanas de transición entre bimestres. El núcleo experimental (sprints 5 a 7) recibe 110 horas técnicas, lo que refleja su carácter central. El cuarto bimestre (sprints 9 a 11) concentra la *demo*, la revisión integral del *pipeline* y de la documentación, la preparación de la defensa y la entrega final.

Cuadro 6. Planificación de sprints (1/3).

Sprint	HU o fase	Tarea	Horas	Resp.	%
Sprint 0	No téc.	Def. alcance, cronograma y <i>backlog</i> ; reuniones con orientadora y cliente	30 h	Al.	0
Sprint 0	Planif.	Config. entorno, instalación de dependencias y preparación del repositorio	20 h	Al.	0
Sprint 1	HU1	Implementación del módulo de captura facial y generación de <i>embedding</i> de referencia	28 h	Al.	0
Sprint 1	HU1	Implementación del flujo de registro de candidato (datos + <i>embedding</i> + almacenamiento)	10 h	Al.	0
Sprint 1	No téc.	Redacción de informe de avance parcial	12 h	Al.	0
Sprint 2	HU2	Desarrollo del módulo de extracción facial desde imagen de documento	14 h	Al.	0
Sprint 2	HU2	Validación de calidad del recorte y generación del <i>embedding</i> del documento	8 h	Al.	0
Sprint 2	HU3	Implementación del módulo de comparación biométrica (distancia coseno + umbral)	14 h	Al.	0
Sprint 2	HU3	Integración del flujo completo de verificación documento-rostro	14 h	Al.	0
Sprint 3	HU4	Implementación del módulo de validación de calidad de imagen	18 h	Al.	0
Sprint 3	HU4	Diseño de la interfaz de notificación de errores y solicitud de nueva captura	14 h	Al.	0
Sprint 3	No téc.	Redacción de documentación técnica del módulo de registro y verificación	18 h	Al.	0

Cuadro 7. Planificación de sprints (2/3).

Sprint	HU o fase	Tarea	Horas	Resp.	%
Sprint 4	HU5	Implementación del <i>pipeline</i> de verificación en tiempo interactivo al inicio de turno	16 h	Al.	0
Sprint 4	HU5	Desarrollo de la <i>demo</i> del flujo de turno	12 h	Al.	0
Sprint 4	HU6	Implementación del mecanismo de reintento y registro de incidencias	16 h	Al.	0
Sprint 4	No téc.	Reuniones de seguimiento y ajuste del cronograma	6 h	Al.	0
Sprint 5	HU7	Diseño e implementación del panel de configuración de umbral	10 h	Al.	0
Sprint 5	HU8	Diseño del protocolo experimental y descarga de <i>benchmarks</i> (LFW, AgeDB, RFW)	14 h	Al.	0
Sprint 5	HU8	Ejecución de la evaluación <i>baseline</i> (ArcFace, AdaFace preentrenados)	20 h	Al.	0
Sprint 5	No téc.	Redacción de informe de avance	6 h	Al.	0
Sprint 6	HU9	Preparación del subconjunto de <i>fine-tuning</i> de adaptación al dominio (Glint360K o WebFace4M)	8 h	Al.	0
Sprint 6	HU9	Ejecución del <i>fine-tuning</i> de adaptación al dominio de ArcFace	30 h	Al.	0
Sprint 6	No téc.	Monitoreo del entrenamiento y registro de curvas de <i>loss</i> y métricas	12 h	Al.	0

Cuadro 8. Planificación de sprints (3/3).

Sprint	HU o fase	Tarea	Horas	Resp.	%
Sprint 7	HU10	Re-evaluación de modelos ajustados sobre LFW, AgeDB y RFW	20 h	Al.	0
Sprint 7	HU10	Análisis comparativo preentrenado vs ajustado, gráficos y <i>trade-off</i>	18 h	Al.	0
Sprint 7	No téc.	Redacción de sección experimental de la memoria	12 h	Al.	0
Sprint 8	HU11	Integración del clasificador de <i>liveness</i> y evaluación sobre OULU-NPU	18 h	Al.	0
Sprint 8	HU11	Incorporación de la decisión de <i>liveness</i> al <i>pipeline</i> y a la <i>demo</i>	14 h	Al.	0
Sprint 8	HU12	Implementación del <i>harness</i> CLI de evaluación end-to-end	18 h	Al.	0
Sprint 9	HU12	Documentación del <i>harness</i> y comandos de reproducción	6 h	Al.	0
Sprint 9	HU13	Implementación de la <i>demo</i> interactiva con Gradio/Streamlit	18 h	Al.	0
Sprint 9	No téc.	Revisión integral del <i>pipeline</i> y de la documentación	26 h	Al.	0
Sprint 10	No téc.	Preparación de la presentación de defensa	16 h	Al.	0
Sprint 10	No téc.	Ensayos de la exposición con retroalimentación de la orientadora	12 h	Al.	0
Sprint 10	—	Ajustes finales al prototipo según observaciones de la orientadora	10 h	Al.	0
Sprint 10	No téc.	Revisión final de la memoria y preparación de la entrega	12 h	Al.	0
Sprint 11	No téc.	Reuniones finales con orientadora y cliente	18 h	Al.	0
Sprint 11	No téc.	Organización del acto de cierre y agradecimientos	12 h	Al.	0
Sprint 11	No téc.	Entrega final de documentación, código y repositorio	20 h	Al.	0

11. Diagrama de Gantt (sprints)

La figura 2 presenta el diagrama de Gantt del proyecto, tomando como base los sprints definidos en la sección 10. El eje horizontal representa las semanas del proyecto, distribuidas en 4 bimestres curriculares desde el 24 de agosto de 2026 hasta finales de abril de 2027 (34 semanas, aproximadamente 8 meses). Cada fila corresponde a un sprint o a una tarea del sprint. Las tareas técnicas derivadas de historias de usuario se diferencian visualmente de las actividades no técnicas (planificación, documentación, defensa). Las bandas en gris claro representan semanas de transición entre bimestres, dedicadas a revisión, redacción de informes parciales y descanso planificado.




Figura 2. Diagrama de Gantt del proyecto.

El color azul representa tareas técnicas derivadas de historias de usuario, el color naranja representa actividades no técnicas (planificación, documentación, preparación de defensa), el color gris claro representa semanas de transición entre bimestres dedicadas a revisión, redacción de informes parciales y descanso planificado, y el color rojo indica el hito de defensa del trabajo final. La secuencia refleja la dependencia lógica entre sprints: las tareas de captura y extracción (sprints 1–2) son prerequisite de la verificación (sprints 2–4), que a su vez son prerequisite de la evaluación experimental (sprints 5–7), la integración del módulo de *liveness* y del *harness* (sprint 8), la *demo* interactiva (sprint 9) y la preparación de la defensa y el cierre (sprints 10–11). La defensa pública se proyecta para el 23 de abril de 2027.

12. Gobernanza de datos

En esta sección se analiza de manera integral el marco normativo y ético asociado al uso de datos biométricos faciales y al desarrollo de una solución basada en inteligencia artificial para verificación de identidad.

12.1. Cumplimiento normativo

El proyecto involucra datos biométricos faciales (*embeddings* vectoriales derivados de imágenes de rostros), lo que lo ubica en una categoría de datos especialmente sensible desde el punto de vista normativo. A continuación se analiza la aplicabilidad de las normativas relevantes y las condiciones de uso de las fuentes de datos y herramientas empleadas.

12.1.1. Normativas aplicables

Ley 25.326 de Protección de Datos Personales (Argentina). La ley argentina de protección de datos personales clasifica los datos biométricos como datos sensibles (art. 2, inc. 2), cuyo tratamiento requiere autorización expresa del titular y está sujeto a restricciones adicionales. Dado que el proyecto se desarrolla en el ámbito de FIUBA (Argentina), esta normativa es directamente aplicable. Sin embargo, el proyecto no recopila datos biométricos de personas reales: el *fine-tuning* y la evaluación se realizan exclusivamente con *datasets* públicos. Por lo tanto, la obligación de obtención de consentimiento no se activa en la fase de experimentación. No obstante, el prototipo se diseñará considerando los principios de la ley (calidad de datos, finalidad, consentimiento, seguridad) como requisitos de implementación, a fin de sentar las bases para que un eventual despliegue futuro cumpla con la normativa.

Reglamento General de Protección de Datos (GDPR). El GDPR europeo clasifica los datos biométricos como datos personales especiales (art. 9) y su tratamiento está prohibido salvo excepciones (consentimiento explícito, interés público, investigación científica). Aunque el proyecto se ejecuta en Argentina, la mención de GDPR se justifica por dos razones: (1) Leroy Merlin es una empresa internacional con operaciones en Europa, por lo que un eventual despliegue futuro del sistema podría estar sujeto al GDPR; y (2) algunos de los *datasets* públicos utilizados contienen imágenes de personas de múltiples jurisdicciones. El proyecto, al operar en un contexto académico sin datos reales, no activa las obligaciones del GDPR, pero el diseño del prototipo contempla principios como minimización de datos, derecho de supresión y trazabilidad, compatibles con el GDPR.

HIPAA (Health Insurance Portability and Accountability Act). Esta normativa estadounidense regula la protección de datos de salud. No es directamente aplicable al proyecto, ya que el sistema no procesa información de salud. Sin embargo, se menciona por completitud dado que algunos *datasets* públicos de reconocimiento facial podrían contener metadatos asociados a contextos sanitarios en su origen. En el caso de los *datasets* seleccionados, este riesgo no aplica.

12.1.2. Fuentes de datos y licencias

Glnt360K (InsightFace). *Dataset* de aproximadamente 17 millones de imágenes de 360.000 identidades, recopilado para la investigación en reconocimiento facial por el equipo de InsightFace. Se distribuye con licencia de uso académico. Se utilizará como fuente principal para el *fine-tuning*, sobre un subconjunto seleccionado. Se verificará la licencia vigente al momento de la descarga.

WebFace4M (Zenodo, 2023). *Dataset* de aproximadamente 4 millones de imágenes de 200.000 identidades, disponible públicamente a través de Zenodo con licencia clara para uso académico. Se considerará como alternativa o complemento a Glnt360K si la disponibilidad o las condiciones de licencia de este último no fuesen adecuadas.

LFW (Labeled Faces in the Wild). Este *dataset* fue creado por el Laboratorio de Visión Computacional de la Universidad de Massachusetts. Las imágenes fueron obtenidas de artículos de noticias en la web y se distribuyen para uso de investigación académica y no comercial. No se requiere una licencia explícita más allá de la atribución al origen. El uso en este proyecto es exclusivamente académico y de evaluación, lo que es consistente con las condiciones de distribución del *dataset*.

AgeDB. *Dataset* de verificación *cross-age* con 16.488 imágenes de 568 personas, disponible públicamente para uso académico. Se utilizará como *benchmark* para evaluar la capacidad de los modelos ante el envejecimiento.

RFW (Racial Faces in the Wild). *Dataset* diseñado para medir sesgo demográfico en modelos de reconocimiento facial, disponible públicamente para uso académico. Se utilizará para reportar el rendimiento por subgrupo demográfico y vincular el análisis con la ética del uso de datos biométricos.

OULU-NPU o CASIA-FASD. *Datasets* públicos de *spoofing* facial, ampliamente utilizados en la literatura de detección de *liveness*. Se utilizarán para la evaluación del módulo de *liveness* (*baseline*).

Exclusiones explícitas. Se descartan *MS-Celeb-1M* (retractado por Microsoft en 2019 por problemas de consentimiento) y *CASIA-WebFace* (retirado y con licencia ambigua), ambos mencionados en la propuesta original pero no utilizables en el estado actual.

12.1.3. Herramientas y modelos preentrenados

Modelos ArcFace y AdaFace. Las implementaciones preentrenadas se obtienen de repositorios de código abierto (*InsightFace*, *adaface-pytorch*). Los pesos preentrenados se distribuyen bajo licencias compatibles con uso académico. ArcFace fue publicado por Imperial College London y sus pesos se distribuyen para uso académico. AdaFace fue publicado en CVPR 2022 y

sus pesos se distribuyen con licencia académica. No se emplean modelos con licencias restrictivas o comerciales.

Herramientas de *software*. El desarrollo se realiza en Python utilizando bibliotecas de código abierto: PyTorch para *deep learning*, InsightFace / *adaface-pytorch* para los modelos, MTCNN y RetinaFace para detección, scikit-learn para métricas de evaluación, Gradio o Streamlit para la *demo* interactiva. Todas las herramientas son de uso libre y compatibles con el contexto académico del proyecto.

12.1.4. Viabilidad legal

El proyecto es viable desde el punto de vista legal por las siguientes razones: (1) no recopila datos biométricos de personas reales; (2) utiliza exclusivamente *datasets* públicos con licencias compatibles con uso académico; (3) los modelos preentrenados se obtienen de fuentes de código abierto con licencias adecuadas; (4) el prototipo no se despliega en producción ni se integra con sistemas reales de la empresa. Para un eventual despliegue futuro, sería necesario: obtener consentimiento informado de los trabajadores, realizar un análisis de impacto sobre protección de datos (DPIA), implementar mecanismos de supresión y actualización de datos, y designar un responsable del tratamiento de datos.

12.2. Ética en el uso de inteligencia artificial

La verificación de identidad biométrica mediante reconocimiento facial plantea consideraciones éticas significativas que deben abordarse desde el diseño del prototipo, incluso en un contexto académico.

12.2.1. Sesgos en los datos y los modelos

Los *datasets* de reconocimiento facial pueden contener sesgos demográficos que afecten el rendimiento del modelo de manera desigual entre grupos poblacionales. Los sesgos más relevantes para este proyecto son:

- **Sesgo de representación demográfica:** los *datasets* públicos pueden estar sobrerrepresentados en determinados grupos étnicos, rangos de edad o género. Si el modelo se evalúa exclusivamente sobre estos *datasets*, las métricas de rendimiento podrían no reflejar el rendimiento real sobre la población diversa del contexto laboral de Leroy Merlin. Por ejemplo, LFW contiene una proporción significativamente mayor de hombres que de mujeres, y una representación desigual de grupos étnicos.
- **Sesgo de edad:** las imágenes de *datasets* pueden no representar adecuadamente a personas en rangos de edad extremos (muy jóvenes o muy mayores), lo que podría afectar la precisión del sistema en poblaciones laborales con diversidad etaria. La evaluación sobre AgeDB aborda parcialmente esta cuestión al incluir rangos etarios amplios.
- **Sesgo de calidad de imagen:** los *datasets* pueden estar compuestos predominantemente por imágenes de alta calidad, lo que no representa las condiciones reales de captura en el entorno laboral.

Estos sesgos no se originan en una intención discriminatoria, sino en limitaciones de las fuentes de datos disponibles. El uso de RFW como uno de los *benchmarks* del proyecto permite cuantificar la brecha de rendimiento entre subgrupos demográficos y documentarla explícitamente en la memoria.

12.2.2. Riesgos de impacto social

El uso indebido de un sistema de verificación biométrica puede generar los siguientes riesgos:

- **Exclusión o discriminación:** si el sistema presenta una tasa de falsos rechazos significativamente mayor para ciertos grupos demográficos, los trabajadores afectados podrían enfrentar demoras, revisiones adicionales o negación del acceso, lo que generaría una experiencia laboral desigual.
- **Uso más allá de la finalidad declarada:** el sistema de verificación podría ser utilizado para fines distintos a la verificación de identidad al inicio de turno, como vigilancia continua del personal, seguimiento de movimientos o evaluación de rendimiento, lo que excedería la finalidad original del proyecto y podría vulnerar derechos laborales y de privacidad.
- **Dependencia tecnológica:** una confianza excesiva en la verificación automática podría reducir la supervisión humana, creando riesgos cuando el sistema falla o produce resultados ambiguos.
- **Almacenamiento inadecuado de datos biométricos:** si los *embeddings* faciales no se protegen adecuadamente, podrían ser objeto de acceso no autorizado, con consecuencias graves para la privacidad de los trabajadores, dado que los datos biométricos son irremplazables.
- **Sistema trivialmente derrotable sin *liveness* robusto:** un sistema de verificación facial sin detección de *liveness* puede ser engañado con una foto impresa del trabajador registrado, lo que anula su utilidad como mecanismo de seguridad.

12.2.3. Medidas de mitigación

Para abordar los riesgos identificados, el prototipo incorpora las siguientes medidas desde su diseño:

- **Evaluación con protocolos estándar:** la evaluación comparativa de modelos se realizará sobre protocolos establecidos (LFW, AgeDB, RFW) que permitan reproducción independiente y comparación con la literatura.
- **Documentación de limitaciones:** la memoria técnica documentará explícitamente las limitaciones de los *datasets* en cuanto a representación demográfica, y señalará que las métricas de rendimiento podrían no ser representativas de poblaciones no representadas en los datos de evaluación.
- **Minimización de datos:** el prototipo almacena únicamente *embeddings* vectoriales (representaciones numéricas compactas), no imágenes faciales. Los registros de auditoría no contienen imágenes ni *embeddings*, solo metadatos de la verificación.

- **Control de acceso:** el almacenamiento de *embeddings* está protegido por mecanismos de control de acceso que restringen la consulta y manipulación a los usuarios autorizados.
- **Derecho de supresión:** el prototipo implementa mecanismos para eliminar o actualizar registros de candidatos o trabajadores, sentando las bases para el cumplimiento del derecho de supresión (“derecho al olvido”).
- **Revisión humana:** el sistema no emite decisiones definitivas de manera autónoma. Ante rechazos o situaciones ambiguas, el flujo prevé derivación a revisión manual, manteniendo al ser humano como decisor final.
- **Finalidad acotada:** el sistema se diseña exclusivamente para verificación de identidad al inicio de turno y en el proceso de selección. No se implementan funcionalidades de reconocimiento en tiempo real continuo, seguimiento o identificación de personas en multitudes.
- **Módulo de *liveness* como *baseline*:** se incluye un clasificador de *liveness* preentrenado como línea base, con la advertencia explícita de que su desarrollo robusto queda como trabajo futuro. Este enfoque reconoce la limitación actual del sistema y abre la puerta a una iteración posterior (por ejemplo, en una etapa de maestría) donde se incorporen arquitecturas más modernas y datos del dominio.

12.2.4. Reflexión ética general

La verificación de identidad biométrica mediante reconocimiento facial es una tecnología con un potencial significativo para mejorar la seguridad operativa, pero que conlleva riesgos inherentes relacionados con la privacidad, la equidad y la proporcionalidad del uso de datos sensibles.

En el contexto de este proyecto, la decisión de operar exclusivamente con *datasets* públicos y sin datos reales de trabajadores es una elección ética deliberada que permite evaluar la viabilidad técnica del sistema sin exponer la privacidad de personas concretas. No obstante, el diseño del prototipo contempla los principios éticos que serían necesarios en un escenario de despliegue real: consentimiento informado, finalidad específica, minimización de datos, seguridad y derecho de supresión.

El proyecto reconoce que la automatización de la verificación de identidad no debe sustituir el juicio humano sino complementarlo. El sistema propuesto emite una recomendación (aceptado/rechazado) que debe ser validada por un responsable, especialmente en casos límite. Esta decisión de diseño refleja el principio de que la inteligencia artificial debe estar sujeta a supervisión humana en contextos donde las decisiones afectan directamente a las personas.

El análisis comparativo de modelos incluye la evaluación de sesgos demográficos como parte del proceso de selección, de modo que la elección del modelo del prototipo no se base únicamente en métricas agregadas de precisión sino también en la equidad del rendimiento entre diferentes grupos poblacionales.

13. Gestión de riesgos

a) Identificación de los riesgos y estimación de sus consecuencias.

Riesgo 1: capacidad computacional insuficiente en *tiers* gratuitos para ejecutar el *fine-tuning* completo.

- Severidad (S): 8. La indisponibilidad de cómputo bloquearía la entrega de la HU9 y, con ella, el núcleo experimental del proyecto. Implicaría reformular el alcance o aceptar un resultado parcial no publicable.
- Probabilidad de ocurrencia (O): 5. Google Colab limita sesiones a 12 h y disponibilidad por día; Kaggle ofrece 30 h semanales de P100; un *fine-tuning* serio puede requerir 20-40 h de GPU continuas o acumuladas, con riesgo real de quedarse corto o sufrir desconexiones.

Riesgo 2: el *fine-tuning* no produce una mejora medible sobre el *baseline* en los *benchmarks* seleccionados.

- Severidad (S): 6. Si la mejora es nula o marginal, el núcleo experimental del trabajo se debilita. No es bloqueante, pero obliga a reorientar el análisis (interpretación de por qué no mejoró, comparación con literatura, ablación).
- Probabilidad de ocurrencia (O): 4. Modelos modernos preentrenados sobre grandes *datasets* ya tienen un *baseline* alto; un subconjunto pequeño puede no aportar información nueva al modelo. Es un riesgo real que debe preverse y documentarse.

Riesgo 3: LFW saturado impide diferenciar ArcFace de AdaFace sobre el *benchmark* de *baseline*.

- Severidad (S): 5. La diferenciación entre los dos modelos se desplazaría hacia AgeDB y RFW, lo que cambia la narrativa pero no impide el trabajo. El *benchmark* LFW quedaría como prueba de saturación más que de diferenciación.
- Probabilidad de ocurrencia (O): 7. Tanto ArcFace como AdaFace rinden ¿99 % en LFW desde hace años; la probabilidad de obtener EER menores al 0.5 % en ambos es muy alta.

Riesgo 4: *dataset* principal de *fine-tuning* (Glint360K o WebFace4M) se vuelve inaccesible o cambia de licencia durante el proyecto.

- Severidad (S): 7. Bloquea la HU9 y obliga a reentrenar o reemplazar el subconjunto. El cronograma se vería afectado.
- Probabilidad de ocurrencia (O): 2. Ambos *datasets* están alojados en repositorios institucionales estables; cambios de licencia son improbables en el horizonte de 8 meses, pero no imposibles.

Riesgo 5: agotamiento de tiempo o burnout del responsable.

- Severidad (S): 9. El proyecto es individual; si el responsable no puede dedicar las horas estimadas, la entrega se atrasa o se degrada la calidad.

- Probabilidad de ocurrencia (O): 5. Carga de 600 h en 8 meses implica un promedio de 20 h semanales con picos de 25 h en los sprints más cortos, ambicioso pero alcanzable; eventos personales, laborales o académicos pueden reducir la disponibilidad real.

Riesgo 6: los datos sintéticos para el cotejo documento–rostro (HU2/HU3) no son representativos de los documentos reales de Leroy Merlin.

- Severidad (S): 5. Si el prototipo se evalúa con documentos sintéticos, su utilidad en producción quedaría condicionada; sin embargo, el alcance del proyecto es académico y se documenta explícitamente.
- Probabilidad de ocurrencia (O): 5. La generación de pares sintéticos controlados a partir de *datasets* públicos es estándar, pero la calidad del recorte puede degradarse con tipos de documentos no representados.

b) **Tabla de gestión de riesgos** (el RPN se calcula como $RPN = S \times O$).

Riesgo	S	O	RPN	S*	O*	RPN*
Capacidad computacional insuficiente en <i>tiers</i> gratuitos (R1)	8	5	40	5	3	15
<i>Fine-tuning</i> sin mejora medible sobre el <i>baseline</i> (R2)	6	4	24	6	4	24
LFW saturado no diferencia modelos (R3)	5	7	35	3	3	9
<i>Dataset</i> principal inaccesible o cambio de licencia (R4)	7	2	14	7	2	14
Agotamiento de tiempo o burnout (R5)	9	5	45	7	3	21
Datos sintéticos no representativos para cotejo documento–rostro (R6)	5	5	25	5	5	25

c) **Criterio adoptado.**

Se tomarán medidas de mitigación en los riesgos cuyo RPN original supere 30. Aplica a R1, R3 y R5.

Nota: los valores marcados con (*) en la tabla corresponden a las estimaciones luego de aplicada la mitigación. Para los riesgos que no superan el umbral de RPN adoptado (R2, R4 y R6) no se elabora plan de mitigación y se repiten los valores originales.

d) **Plan de mitigación de los riesgos que originalmente excedían el RPN máximo establecido.**

R1 — Capacidad computacional insuficiente en *tiers* gratuitos.

- **Acción:** reducir el tamaño del subconjunto de *fine-tuning* al mínimo que permita una conclusión estadísticamente interpretable (por ejemplo, 50.000–100.000 imágenes en lugar de 300.000); priorizar el *fine-tuning* de un solo modelo (ArcFace) y dejar el de AdaFace como opcional; entrenar por capas (congelar las convolucionales tempranas) para reducir cómputo; documentar tiempos y recursos consumidos en cada corrida.
- Severidad revisada (S*): 5. La reducción del subconjunto y el *fine-tuning* por capas permiten ejecutar el experimento dentro de los límites de los *tiers* gratuitos; el peor caso es un subconjunto más pequeño con resultado menos contundente, no la imposibilidad de ejecutar.

- Ocurrencia revisada (O^*): 3. Con el subconjunto reducido y el esquema por capas, las horas de GPU necesarias caen a un rango compatible con Colab Pro (USD 10/mes) o con un saldo de Kaggle generoso, accesibles con presupuesto mínimo.

R3 — LFW saturado no diferencia modelos.

- **Acción:** aceptar LFW como prueba de saturación (no de diferenciación) y enfocar la diferenciación en AgeDB (*cross-age*) y RFW (sesgo demográfico), donde se esperan brechas visibles. Reportar explícitamente la saturación y discutir su significado en la memoria.
- Severidad revisada (S^*): 3. Al reorientar la diferenciación hacia AgeDB y RFW, la saturación de LFW deja de ser un problema experimental: el resultado de saturación en sí mismo es un hallazgo publicable y refuerza la decisión metodológica de incorporar *benchmarks* más exigentes.
- Ocurrencia revisada (O^*): 3. AgeDB y RFW son los *benchmarks* donde se espera la diferenciación real; la probabilidad de obtener EER distinguibles entre ArcFace y AdaFace en esos dos es alta.

R5 — Agotamiento de tiempo o burnout.

- **Acción:** priorizar las HU de los sprints 5 a 7 (núcleo experimental) por sobre las HU de los sprints 1 a 4 (pipeline base). Si el cronograma se ve comprometido, reducir el alcance de las HU de infraestructura (por ejemplo, simplificar la HU4 de manejo de capturas inválidas) antes que reducir el alcance experimental. Solicitar extensión del plazo al posgrado si la situación lo requiere.
- Severidad revisada (S^*): 7. La priorización del núcleo experimental reduce la probabilidad de tener que rehacer trabajo central.
- Ocurrencia revisada (O^*): 3. Con priorización clara y plan de extensión como red de seguridad, el riesgo de no llegar a la entrega baja.

14. Sprint Review

La revisión de sprint (*Sprint Review*) es una práctica fundamental en metodologías ágiles. Consiste en revisar y evaluar lo que se ha completado al finalizar un sprint. En esta instancia, se presentan los avances y se verifica si las funcionalidades cumplen con los criterios de aceptación establecidos. También se identifican entregables parciales y se consideran ajustes si es necesario.

Aunque el proyecto aún se encuentre en etapa de planificación, esta sección permite proyectar cómo se evaluarán las funcionalidades más importantes del *backlog*. Esta mirada anticipada favorece la planificación enfocada en valor y permite reflexionar sobre posibles obstáculos.

Objetivo: anticipar cómo se evaluará el avance del proyecto a medida que se desarrollen las funcionalidades, utilizando como base al menos cuatro historias de usuario del *Product Backlog*.

Se seleccionan las HU1, HU5, HU8 y HU9, que cubren tanto el *pipeline* base (captura, verificación en tiempo interactivo) como el núcleo experimental (evaluación comparativa y *fine-tuning*).

HU seleccionada	Tareas asociadas	Entregable esperado	¿Cómo sabrás que está cumplida?	Observaciones o riesgos
HU1	Implementación del módulo de captura facial y del flujo de registro (38 h en Sprint 1)	Módulo de captura y registro funcional con <i>embedding</i> almacenado	Detección de un rostro, <i>embedding</i> generado y recuperado correctamente; criterios de aceptación de HU1 cumplidos	Validar con cámara real; la calidad de la cámara afecta el EER de toda la cadena
HU5	Implementación del <i>pipeline</i> de verificación en tiempo interactivo al inicio de turno (28 h en Sprint 4)	Módulo de verificación en vivo funcional con indicador de aceptado/rechazado	<i>Pipeline</i> ejecuta en menos de 5 s en el <i>hardware</i> de referencia; criterios de aceptación de HU5 cumplidos	La latencia de captura y procesamiento en el <i>hardware</i> de referencia puede ser ajustada
HU8	Diseño del protocolo experimental y ejecución de la evaluación <i>baseline</i> de ArcFace y AdaFace sobre LFW, AgeDB y RFW (34 h en Sprint 5)	Tablas y curvas ROC comparativas preentrenadas; métricas EER, FAR, FRR, AUC	Resultados documentados con semillas, configuración y particiones; criterios de aceptación de HU8 cumplidos	Riesgo de que LFW esté saturado y no diferencie modelos (R3); respaldarse en AgeDB y RFW
HU9	Preparación del subconjunto de <i>fine-tuning</i> de adaptación al dominio y ejecución del ajuste de ArcFace sobre Glint360K o WebFace4M (38 h en Sprint 6)	Modelo ArcFace ajustado con curvas de <i>loss</i> y <i>checkpoints</i> intermedios	EER sobre AgeDB y sobre las variantes degradadas mejorado respecto del <i>baseline</i> , o análisis documentado de por qué no mejoró; criterios de aceptación de HU9 cumplidos	Riesgo de capacidad computacional (R1) y de no observar mejora (R2)

15. Sprint Retrospective

La retrospectiva de sprint es una práctica orientada a la mejora continua. Al finalizar un sprint, el equipo (o el alumno, si trabaja de forma individual) reflexiona sobre lo que funcionó bien, lo que puede mejorarse y qué acciones concretas pueden implementarse para trabajar mejor en el futuro.

Durante la cursada se propuso el uso de la **Estrella de la Retrospectiva**, que organiza la reflexión en torno a cinco ejes:

- ¿Qué hacer más?
- ¿Qué hacer menos?
- ¿Qué mantener?
- ¿Qué empezar a hacer?
- ¿Qué dejar de hacer?

Aun en una etapa temprana, esta herramienta permite que el alumno planifique su forma de trabajar, identifique anticipadamente posibles dificultades y diseñe estrategias de organización personal.

Objetivo: reflexionar sobre las condiciones iniciales del proyecto, identificando fortalezas, posibles dificultades y estrategias de mejora, incluso antes del inicio del desarrollo.

Se completa la tabla para tres sprints técnicos (Sprint 1 de captura facial, Sprint 6 de *fine-tuning* y Sprint 9 de *demo* y revisión) y un sprint no técnico (Sprint 10 de preparación de la defensa), en línea con los hitos centrales del proyecto.

Sprint tipo y N°	¿Qué hacer más?	¿Qué hacer menos?	¿Qué mantener?	¿Qué empezar a hacer?	¿Qué dejar de hacer?
Sprint técnico 1 (Captura facial)	Pruebas con cámara e iluminación real desde el inicio; documentar decisiones de diseño en el repositorio	Reescribir módulos sin versionar; posponer la lectura de la documentación de InsightFace	Commits pequeños y frecuentes con mensajes descriptivos; instalación del entorno en una máquina de referencia	Registrar <i>issues</i> y dudas en un <i>log</i> de proyecto; correr pruebas con <i>datasets</i> sintéticos antes de integrar	Cambiar de modelo o librería sin evaluar impacto
Sprint técnico 6 (<i>fine-tuning</i>)	Monitoreo de <i>loss</i> y validación durante el entrenamiento; documentar hiperparámetros y semillas	Reentrenar desde cero ante cada cambio; experimentar sin guardar <i>checkpoints</i>	Registro riguroso de la configuración experimental; uso de Weights & Biases (<i>wandb</i>) o equivalente para el <i>tracking</i>	Comparar curvas de entrenamiento entre modelos; calcular tiempo total de cómputo consumido	Modificar <i>learning rate</i> o esquema de <i>freeze</i> sin justificación documentada
Sprint técnico 9 (<i>demo</i> y revisión)	Pruebas de extremo a extremo con la <i>demo</i> ; revisión cruzada de la documentación con la orientadora	Postergar <i>bugs</i> conocidos del <i>pipeline</i> por avanzar con la <i>demo</i> ; acumular deuda técnica sin documentarla	<i>Demo</i> reproducible con un único comando; <i>README</i> claro del repositorio	Hacer <i>screencasts</i> cortos de la <i>demo</i> para la defensa; pedirle a un tercero que ejecute el <i>harness</i> desde cero	Depurar en vivo durante la defensa
Sprint no técnico 10 (Defensa)	Ensayos cronometrados con público; simulacro de preguntas del tribunal	Reescribir slides de último momento; excederse en detalles técnicos secundarios	Estructura clara: problema, solución, experimento, resultados, limitaciones; figuras con etiquetas legibles	Pedirle a un no-especialista que escuche la presentación; preparar respuestas a preguntas frecuentes (“¿por qué no AdaFace en producción?”, “¿cuánto mejora el <i>fine-tuning</i> ?”)	Agregar slides o secciones que no se pueden defender en 15 minutos